

# CAPÍTULO 1

Laplace  $P(A) = \frac{\# \text{casos favorables } A}{\# \text{casos posibles}}$

## Álgebra de Eventos

- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- $P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) + P(A \cap B \cap C)$
- $P(A) = 1 - P(\bar{A})$
- $P(\bar{A} \cap \bar{B}) = 1 - P(A \cup B)$
- $P(\overline{A \cup B \cup C}) = P(\bar{A} \cap \bar{B} \cap \bar{C})$

## Técnicas de Conteo

\* Regla del Producto  $n_A \cdot n_B$

Cantidad de pares ordenados que pueden formarse con un elemento de A y uno de B

\* Permutaciones  $n!$

Combinación de formas  $\neq$  que se puede ordenar

\* Variaciones  $P_{n,r} = \frac{n!}{(n-r)!}$

Combinación de subconjuntos ordenados de r elementos a partir de n

## \* Combinaciones

$$C_{n,r} = \frac{n!}{r!(n-r)!} = \binom{n}{r}$$

Combinación de subconjuntos no ordenados de  $r$

elementos a partir de  $n$

## \* Anagramas

$$\frac{n!}{n_1! n_2! \dots n_k!}$$

Permutaciones con elementos repetidos

## \* Método de Bose-Einstein

$$\binom{r+k-1}{r} = \binom{r+k-1}{k-1}$$

Ordenar  $r$  elementos indistinguibles en  $k$  urnas

## Probabilidad Condicional

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$$P(B) > 0$$

### • Propiedades

$$\rightarrow P(A \cup C|B) = P(A|B) + P(C|B) \quad A \cap C = \emptyset$$

$$\rightarrow P(A \cap B) = P(A|B) P(B) = P(B|A) P(A)$$

$$\rightarrow P(A \cap B \cap C) = P(A|B \cap C) \cdot P(B|C) P(C) \rightarrow P(B \cap C)$$

## Probabilidad Total

$$P(A) = \sum_{i=1}^k P(A|B_i) P(B_i)$$

## Teorema de Bayes

$$P(B_i|A) = \frac{P(A|B_i) P(B_i)}{\sum_{j=1}^k P(A|B_j) P(B_j)}$$

↓  
prob de la  
partición

→ proba de A  
sobre la partición  
→ proba total  
de A

## Eventos Independientes

$$P(A \cap B) = P(A) P(B)$$

## CAPÍTULO 2

### Variables Aleatorias

\* Función de Distribución  $F_x(x) = P(x \leq x)$

$$\rightarrow P(a < x \leq b) = F_x(b) - F_x(a)$$

\* Discretos

$$\rightarrow P(x=x) = p_x(x)$$

$$\rightarrow p_x(x_j) = P(x=x_j) = F_x(x_j) - F_x(x_{j-1}) \rightarrow F_x \in \text{escalonada}$$

\* Continuos

$$\rightarrow P(a < x < b) = \int_a^b f_x(x) dx$$

$$\rightarrow F_x(x) = P(x \leq x) = \int_{-\infty}^x f_x(t) dt$$

$$\rightarrow f_x(x) = \frac{d}{dx} F_x(x) \rightarrow f_x \in \text{continua}$$

### Función de Variable Aleatoria

$$\rightarrow f_y(y) = P(y \leq y) = P(g(x) \leq y)$$

Simulación Dos eventos son equivalentes cuando

acumulan la misma probabilidad

### Truncamiento

$$\rightarrow f_{x|x \in A}(x) = P(x \leq x | x \in A) = \frac{P(x \leq x, x \in A)}{P(x \in A)}$$

$$\rightarrow f_{x_1 \times \dots \times x_n}(x) = \frac{\partial}{\partial x} F_{x_1 \times \dots \times x_n}(x) = \frac{f_x(x) \mathbb{1}_{\{x \in A\}}}{P(x \in A)} \rightarrow x \in \text{VAC}$$

Vectores Aleatorios  $f_{\mathbf{x}}(\mathbf{x}) = P(x_1 \leq x_1, \dots, x_n \leq x_n)$

\* **Discreto**  $p_{x,y}(x,y) = P(x=x, y=y)$

$$\rightarrow p_x(x) = \sum_y p_{x,y}(x,y)$$

$$\rightarrow p_y(y) = \sum_x p_{x,y}(x,y)$$

$$\rightarrow P((x,y) \in A) = \sum \sum_{(x,y) \in A} p_{x,y}(x,y)$$

\* **Continuo**

$$\rightarrow P((x,y) \in A) = \iint_A f_{x,y}(x,y) dx dy$$

$$\rightarrow f_x(x) = \int_{-\infty}^{\infty} f_{x,y}(x,y) dy$$

$$\rightarrow f_y(y) = \int_{-\infty}^{\infty} f_{x,y}(x,y) dx$$

\* **Independencia**  $P((x \in A) \cap (y \in B)) = P(x \in A) P(y \in B)$

$$\rightarrow f_{\mathbf{x}}(\mathbf{x}) = f_{x_1}(x_1) \dots f_{x_n}(x_n)$$

$$\rightarrow p_{\mathbf{x}}(\mathbf{x}) = p_{x_1}(x_1) \dots p_{x_n}(x_n)$$

$$\rightarrow f_{\mathbf{x}}(\mathbf{x}) = f_{x_1}(x_1) \dots f_{x_n}(x_n)$$

$\Leftrightarrow x_1, \dots, x_n$  son independientes

## CAPÍTULO 3

### Esperanza de una Variable Aleatoria

$$\rightarrow E[h(x)] = \sum_{x \in A} h(x) P(x=x) + \int_{\mathbb{R} \setminus A} h(x) f'_x(x) dx$$

\* **Discreto**  $E[h(x)] = \sum_{x \in A_x} h(x) p_x(x)$

\* **Continuo**  $E[h(x)] = \int_{-\infty}^{\infty} h(x) f_x(x) dx$

#### \* Propiedades

- $h(x) = ax + b \therefore E[h(x)] = a E[x] + b \rightarrow$  linealidad

- $E[x | x \in A] = \frac{E[x | \{x \in A\}]}{P(x \in A)} \rightarrow$  esperanza parcial

- $E[x] = E[x | x \in A] P(x \in A) + E[x | x \in \bar{A}] P(x \in \bar{A}) \rightarrow$  esperanza total

- $E[x] = \int_0^{\infty} (1 - F_x(x)) dx - \int_{-\infty}^0 F_x(x) dx \rightarrow$  área por encima de  $f_x$

### Varianza de una Variable Aleatoria

$$\rightarrow \text{Var}(x) = E[(x - E[x])^2] = E[x^2] - E[x]^2$$

\* **Desvio Estándar**  $\sigma_x = \sqrt{\text{Var}(x)}$

### Esperanza de un Vector Aleatorio

$$\rightarrow E[h(x, y)] = \sum_x \sum_y h(x, y) p_{x,y}(x, y) \rightarrow (x, y) \in VAD$$

$$\rightarrow E[h(x, y)] = \iint_{\mathbb{R}^2} h(x, y) f_{x,y}(x, y) dx dy \rightarrow (x, y) \in VAC$$

#### \* Propiedades

- $E[1 \times 1] \geq E[x]$
- $E[1 \times y] = \sqrt{E[x^2] E[y^2]}$
- $E\left[\sum_{i=1}^n a_i x_i\right] = \sum_{i=1}^n a_i E[x_i]$
- $E\left[\sum_{i=1}^n x_i\right] = \sum_{i=1}^n E[x_i], \quad x_1, \dots, x_n \text{ son independientes}$

## Covarianza de un Vector Aleatorio

$$\rightarrow \text{cov}(x, y) = E[(x - E[x])(y - E[y])]$$

$$\rightarrow \text{cov}(x, y) = E[xy] - E[x]E[y]$$

$$\rightarrow (x, y) \text{ indep} \therefore \text{cov}(x, y) = 0$$

$$\rightarrow \text{cov}(a + bx, c + dy) = bd \text{cov}(x, y) \rightarrow \text{colinealidad}$$

$$\rightarrow \text{cov}(x+y, z) = \text{cov}(x, z) + \text{cov}(y, z)$$

$$\rightarrow \text{var}(x+y) = \text{var}(x) + \text{var}(y) + 2 \text{cov}(x, y)$$

## Coeficiente de Correlación de un Vector Aleatorio

$$\rightarrow \rho_{x,y} = \frac{\text{cov}(x, y)}{\sqrt{\text{var}(x)\text{var}(y)}}, \quad -1 \leq \rho_{x,y} \leq 1$$

## Predicción $ECM = E[(y - g(x))^2]$

$$\star g(x) = C \quad ECM = \text{var}(y)$$

$$\star g(x) = a + bx \quad \hat{y} = \frac{\text{cov}(x, y)}{\text{var}(x)} (x - E[x]) + E[y]$$

RECTA DE  
REGRESIÓN LINEAL

## Desigualdades

\* De Markov  $P(|x| \geq t) \leq \frac{E[h(x)]}{h(t)}, \forall t \in \mathbb{R}$

\* De Tchernychev  $P(|x - E[x]| \geq u) \leq \frac{Var(x)}{u^2}, \forall u > 0$

## CAPÍTULO 4

Método del Jacobiano  $f_{U_1, U_2}(u_1, u_2) = \frac{f_{Y_1, Y_2}(y_1, y_2)}{|J|}$

Teorema 4.14  $x_1 \sim \mathcal{E}(\lambda_1), x_2 \sim \mathcal{E}(\lambda_2)$  independientes

$$U = \min(x_1, x_2) \quad W = V - U$$

$$V = \max(x_1, x_2) \quad J = 21\{V = x_1\} + 221\{V = x_2\}$$

- $U \sim \mathcal{E}(\lambda_1 + \lambda_2)$

- $P(J=1) = \frac{\lambda_1}{\lambda_1 + \lambda_2}, \quad P(J=2) = \frac{\lambda_2}{\lambda_1 + \lambda_2}, \quad P(J_i) = \frac{\lambda_i}{\sum_{i=1}^n \lambda_i}$
- $f_W(w) = \frac{\lambda_1}{\lambda_1 + \lambda_2} \lambda_2 e^{-\lambda_2 w} + \frac{\lambda_2}{\lambda_1 + \lambda_2} \lambda_1 e^{-\lambda_1 w}, \quad w > 0$

"quién gana"

## Suma de VA

- $x_i \stackrel{\text{iid}}{\sim} \text{Poi}(\lambda_i) \therefore \sum x_i \sim \text{Poi}(\sum \lambda_i)$
- $x_i \stackrel{\text{iid}}{\sim} \text{Ber}(p) \therefore \sum x_i \sim \text{B}(n, p)$
- $x_i \stackrel{\text{iid}}{\sim} g(p) \therefore \sum x_i \sim \text{Poi}(n, p)$
- $x_i \stackrel{\text{iid}}{\sim} \mathcal{E}(\lambda) \therefore \sum x_i \sim \Gamma(n, \lambda)$
- $x_i \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu, \sigma^2) \therefore \sum x_i \sim \mathcal{N}(n\mu, n\sigma^2)$
- $z_i \stackrel{\text{iid}}{\sim} \mathcal{N}(0, 1) \therefore \sum z_i \sim \chi^2(n)$
- $x_i \stackrel{\text{iid}}{\sim} \chi^2_{2\lambda_i} \therefore \sum x_i \sim \chi^2(\sum 2\lambda_i)$
- $x_1, x_2 \stackrel{\text{iid}}{\sim} \mathcal{U}(0, 1) \quad w = x_1 + x_2 \in \text{triangulito}$

•  $x_i \sim \text{Ray}(\theta) \therefore \sum_{i=1}^n x_i^2 \sim \Gamma(n, \frac{1}{2\theta^2})$

## CAPÍTULO 5

### Variables Aleatorias Condicionadas

#### \* Discreto

$$\rightarrow P_{Y|X=x}(y) = P(Y=y | X=x) = \frac{P(X=x, Y=y)}{P(X=x)} = \frac{P_{X,Y}(x,y)}{P_X(x)}$$

$$\rightarrow P_{X,Y}(x,y) = P_{Y|X=x}(y) P_X(x)$$

$$\rightarrow P_{X,Y}(x,y) = P_{X|Y=y}(x) P_Y(y)$$

$$\rightarrow P_{Y|X=x}(y) = P_Y(y) \quad \forall x \in \mathbb{R} \Rightarrow X \text{ e } Y \text{ son independientes}$$

#### \* Continuo

$$\rightarrow f_{Y|X=x}(y) = \frac{f_{X,Y}(x,y)}{f_X(x)}$$

$$\rightarrow f_{X,Y}(x,y) = f_{Y|X=x}(y) f_X(x)$$

$$\rightarrow f_{X,Y}(x,y) = f_{X|Y=y}(x) f_Y(y)$$

### Mezcla de Variables Aleatorias

$$\rightarrow f_X(x) = P(X \leq x) = \sum_{i=1}^n F_{X|A_i}(x) P(A_i) \rightarrow \text{probabilidad total}$$

$$\star \text{ Variable Mezcladora} \quad f_X(x) = \sum_{m \in M} f_{X|M=m}(x) P(M=m)$$

$$\bullet \quad P_X(x) = \sum_{m \in M} P_{X|M=m}(x) P(M=m)$$

$$\bullet \quad f_X(x) = \sum_{m \in M} f_{X|M=m}(x) P(M=m)$$

### Bayes para Mezclas

$$P_{M|X=x}(m) = \frac{f_{X|M=m}(x) P(M=m)}{\sum_{i \in M} f_{X|M=i}(x) P(M=i)}$$

## Esperanza de $Y$ condicionada a $X$ (función Regresión $\hat{Y}(x)$ )

\* **Discretos**  $E[Y|X=x] = \sum_{y \in \mathcal{Y}_{Y|X=x}} y \cdot P_{Y|X=x}(y)$

\* **Continuos**  $E[Y|X=x] = \int_{-\infty}^{\infty} y \cdot f_{Y|X=x}(y) dy$

## Esperanza Condicional $\hat{Y}(x) = E[Y|X] \rightarrow \in VA$

→  $E[E[Y|X]] = E[Y]$

→  $E[r(x) \cdot s(Y) | X] = r(x) E[s(Y) | X]$

→  $E[aY_1 + bY_2 | X] = a E[Y_1 | X] + b E[Y_2 | X]$

→  $E[Y|X] = E[Y]$  si  $X$  e  $Y$  son independientes

→  $E[r(X) | X] = r(X)$

→  $E[X \cdot Y] = E[X \cdot E[Y|X]]$

## Varianza de $Y$ Condicionada a $X$ ( $\text{Cov}(x)$ )

→  $\text{Cov}(x) = \text{Var}(Y|X=x) = E[(Y - E[Y|X=x])^2 | X=x]$

## Varianza Condicional $\text{Cov}(x) = \text{Var}(Y|X) \rightarrow \in VA$

→  $\text{Var}(Y|X) = E[Y^2|X] - E[Y|X]^2$

\* **Pitágoras**  $\text{Var}(Y) = E[\text{Var}(Y|X)] + \text{Var}(E[Y|X])$


## CAPÍTULO 6

### Proceso Bernoulli


- dicotomía
  - probabilidad constante
  - experimentos independientes
- ★  $x_i$ : "ocurre el evento i"  $\sim \text{Ber}(p)$
- ★  $Y$ : "# éxitos en n ensayos" =  $\sum_{i=1}^n x_i \sim \text{B}(n, p)$
- ★  $N$ : "# ensayos hasta 1º éxito"  $\sim \text{g}(p)$
- ★  $W$ : "# ensayos hasta k éxitos" =  $\sum_{i=1}^k N_i \sim \text{Pas}(k, p)$

# CAPÍTULO 7


## Proceso de Poisson



## \* Adelgazamiento & Colores



## \* Superposición



## \* Distribución condicional tiempo de llegada

→  $s_i$ : momento en el que ocurre el arribo  $i$

$$(s_1, \dots, s_n) \sim U(0, t) \quad \therefore (s_1, \dots, s_n) | N(t) = n \sim M\left(n, \frac{\alpha}{t}, \dots, \frac{t-c}{t}\right)$$

## CAPÍTULO 8

### Estandarización

$$x \sim N(\mu, \sigma^2) \therefore z = \frac{x-\mu}{\sigma} \sim N(0,1)$$

### Teoremas Límites

$$x_1, \dots, x_n \text{ iid}, E[x_i] = \mu < \infty, \text{Var}(x_i) = \sigma^2 < \infty$$

\* Ley de los Grandes Números  $\bar{x} \rightarrow \mu$

\* Ley de los Grandes Números (Monkov)

$$P(|\bar{x}_n - \mu| > \varepsilon) \xrightarrow[n \rightarrow \infty]{\rightarrow 0}, E(\bar{x}_n) = \mu, \text{Var}(\bar{x}_n) = \frac{\sigma^2}{n}$$

\* Teorema central del límite

$$\frac{\sum_{i=1}^n x_i - n\mu}{\sqrt{n\sigma^2}} \xrightarrow{\mathbb{P}} z \sim N(0,1)$$

### Propiedades

$$\bullet z \sim N(0,1) \therefore z^2 \sim \chi^2$$

$$\bullet z \sim N(0,1), v \sim \chi^2_n, z \text{ y } v \text{ indep } \therefore \frac{z}{\sqrt{v/n}} \sim t_n$$

$$\bullet \bar{x} \xrightarrow{\text{iid}} N(\mu, \sigma^2) \therefore \frac{\sqrt{n}}{\sigma} (\bar{x} - \mu) \sim N(0,1)$$

$$\bullet \bar{x} \xrightarrow{\text{iid}} N(\mu, \sigma^2) \therefore \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{\sigma^2} \sim \chi^2_{n-1}$$

$$\bullet \bar{x} \xrightarrow{\text{iid}} N(\mu, \sigma^2), s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} \therefore T = \frac{\sqrt{n}(\bar{x} - \mu)}{s} \sim t_{n-1}$$

$$\bullet x \sim N(\mu, \sigma^2), c > 0 \therefore \begin{cases} x + c \sim N(\mu + c, \sigma^2) \\ cx \sim N(\mu c, \sigma^2 c^2) \end{cases}$$

# CAPÍTULO 9

## Función de Verosimilitud

\* Discreto  $l(\theta) = \prod_{i=1}^n p_\theta(x_i)$

\* Continuo  $l(\theta) = \prod_{i=1}^n f_\theta(x_i)$

Familias Exponenciales  $f_\theta(x) = A(\theta) e^{\sum_{i=1}^k c_i(\theta) r_i(x)} h(x)$

\*  $x \sim \text{Ber}(p)$   $f_p(x) = (1-p) e^{x \ln(\frac{p}{1-p})} \quad \text{si } x \in \{0,1\}$

\*  $x \sim \text{Poi}(\kappa, \theta)$   $f_\theta(x) = \theta^x e^{-(\theta+1) \ln(x)} \quad \text{si } x > \kappa$

\*  $x \sim \text{N}$

\*  $x \sim \Gamma(\alpha, \lambda)$   $f_{(\alpha, \lambda)}(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} e^{-\lambda x + \alpha \ln x} e^{-\ln x} \quad \text{si } x > 0$

\*  $x \sim \chi^2$

\*  $x \sim \text{N} \beta$

\*  $x \sim \text{Poi}$

\*  $x \sim g(\theta)$   $f_\theta(x) = \frac{\theta}{1-\theta} e^{x \ln(1-\theta)} \quad \text{si } x \in \mathbb{N}$

## Estadísticos

Dado uno ma  $\underline{x}$ , es una función que da un valor.

No puede depender de parámetros desconocidos.

\* Teorema de factorización  $T = f(\underline{x}) \rightarrow$  estad. suficiente

$$f_{\theta}(\underline{x}) = g(r(\underline{x}), \theta) h(\underline{x})$$

→ familias exponenciales:  $T = \sum_{i=1}^n r(x_i)$

- $\underline{x} \stackrel{\text{iid}}{\sim} U(0, \theta) \therefore T = \max(\underline{x})$

- $\underline{x} \stackrel{\text{iid}}{\sim} \Gamma(\alpha, \lambda) \therefore T = (\sum_{i=1}^n x_i, \sum_{i=1}^n \ln x_i)$

Estimador valor aproximado parámetro desconocido

\* Método Máximo Verosimilitud  $\hat{f}_{\theta}(x) = \max_{\theta} f_{\theta}(x)$

$$\frac{d}{d\theta} \ln(L(\theta)) = 0, \quad L(\theta) = \prod_{i=1}^n f_{\theta}(x_i)$$

- $x \stackrel{iid}{\sim} \text{Ber}(p) \therefore \hat{p} = \frac{1}{n} \sum_{i=1}^n x_i \rightarrow$  sesgado
- $x \stackrel{iid}{\sim} U(0, \theta) \therefore \hat{\theta} = \max(x) \rightarrow$  asintóticamente sesgado
- $x \stackrel{iid}{\sim} \text{Poi}(\lambda, \theta) \therefore \hat{\theta} = \frac{n}{\sum_{i=1}^n \ln(x_i/2)} \rightarrow$  asintóticamente sesgado
- $x \stackrel{iid}{\sim} N(\mu, \sigma^2) \therefore \left\{ \begin{array}{l} \hat{\mu} = \bar{x} \\ \hat{\sigma}^2 = \frac{\sum (x_i - \bar{x})^2}{n} \end{array} \right. \downarrow \text{sesgado} \rightarrow s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$
- $x \stackrel{iid}{\sim} \mathcal{E}(\lambda) \therefore \hat{\lambda} = \frac{1}{\bar{x}}$
- $x \stackrel{iid}{\sim} g(\theta) \therefore \hat{\theta} = \frac{1}{\bar{x}}$
- $x \stackrel{iid}{\sim} \text{Poi}(\mu) \therefore \hat{\mu} = \bar{x}$
- $x \stackrel{iid}{\sim} \text{Ray}(\theta) \therefore \hat{\theta}^2 = \frac{1}{2n} \sum_{i=1}^n x_i^2$

## Principio de Invarianza (Método Plug In)

$$\lambda = q(\theta) \quad \left. \begin{array}{l} \\ \end{array} \right\} \rightarrow \hat{\lambda} = q(\hat{\theta}) \in \text{EMV de } \lambda$$

$\hat{\theta} \in \text{ENV de } \theta$

## Bondad del Estimador

\* Riesgo de estimar a  $\theta$  con  $\hat{\theta}$

$$R(\theta, \hat{\theta}) = \text{ECM}(\hat{\theta}) = E[(\theta - \hat{\theta})^2]$$

\* Insurgado  $E_{\theta}[\hat{\theta}] = \theta$

\* Segado  $B(\hat{\theta}) = E_{\theta}[\hat{\theta}] - \theta$

\* Asiméticamente Insurgado  $\lim_{n \rightarrow \infty} E_{\theta}[\hat{\theta}] = \theta$

\* Débilmente Consistente  $\text{Var}_{\theta}(\hat{\theta}) \rightarrow 0$  y  $E_{\theta}(\hat{\theta}) \rightarrow \theta$

\* Consistencia en Medio Cuadrática  $\lim_{n \rightarrow \infty} \text{ECM}(\hat{\theta}) = 0$

$$\bullet \text{ECM}(\hat{\theta}) = \text{Var}_{\theta}(\hat{\theta}) + B(\hat{\theta})^2$$

## Estimadores Asintóticamente Normales

### \* Número de Información de Fisher

$$I(\theta) = E \left[ \left( \frac{\partial}{\partial \theta} \ln(f_\theta(x)) \right)^2 \right] = -E \left[ \frac{\partial^2}{\partial \theta^2} \ln(f_\theta(x)) \right]$$

### \* Teorema

$$\sqrt{n} \sqrt{I(\theta)} (\hat{\theta}_n - \theta) \xrightarrow{d} N(0, 1) \quad \left. \begin{array}{l} \hat{\theta}_n \in \text{estimador consistente} \end{array} \right\} \rightarrow \sqrt{n} \sqrt{I(\hat{\theta}_n)} (\hat{\theta}_n - \theta) \sim N(0, 1)$$

- $\underline{x} \sim \text{Ber}(p) \quad \therefore I(p) = \frac{1}{p(1-p)}$

## CAPÍTULO 10

### Test de Hipótesis

- $H_1$ : hipótesis del investigador
- $H_0$ : hipótesis nula

### Tipos de Errores

\* EI se rechaza  $H_0$  que era verdadera

\* EII no se rechaza  $H_0$  que era falsa

Es más grave echar a la cárcel a un inocente  $\rightarrow$  EI

que dejar libre a un culpable  $\rightarrow$  EII

$$\bullet P(\text{"EI"}) = P_\theta(\text{"rechazar } H_0\text{"}) = P_\theta(\delta(\underline{x}) = 1) = \Pi_\delta(\theta)$$

$$\bullet P(\text{"EII"}) = P_\theta(\text{"no rechazar } H_0\text{"}) = P_\theta(\delta(\underline{x}) = 0) = 1 - \Pi_\delta(\theta)$$

### Nivel de Significación del Test $\alpha = \sup_{\theta \in \Theta} \Pi_\delta(\theta)$

### P-Valor de un Test probabilidad de encontrar un

valor tan o más extremo que el que se encontró con la muestra.

### Test Hipótesis Simple vs Hipótesis Simple

$$H_0: \theta = \theta_1 \text{ vs } H_1: \theta = \theta_2 \quad \therefore \delta(\underline{x}) = \begin{cases} 1, & \frac{f_{\theta_2}(\underline{x})}{f_{\theta_1}(\underline{x})} > k_\alpha \\ 0, & \text{resto} \end{cases}$$

- $\underline{x} \stackrel{iid}{\sim} N(\mu, \sigma^2)$ ,  $\mu$  desconocido  $\therefore T = \frac{\sum (x_i - \bar{x})^2}{\sigma^2} \rightarrow \chi^2$
- $\underline{x} \stackrel{iid}{\sim} N(\mu, \sigma^2)$ ,  $\sigma$  desconocido  $\therefore T = \frac{\sum (x_i - \bar{x})^2}{\sigma^2} \rightarrow \chi^2$

\* **Propiedades**  $\underline{x} \in \text{una familia exponencial}$

①  $C(\theta)$  creciente

$$H_0: \theta \leq \theta_0$$

$$H_1: \theta > \theta_0$$

$$\left. \begin{array}{c} \left. \begin{array}{c} \text{ } \\ \text{ } \end{array} \right. \\ \rightarrow \end{array} \right\} \delta(\underline{x}) = \begin{cases} 1, & T > k_\alpha \\ 0, & T \leq k_\alpha \end{cases}$$

②  $C(\theta)$  decreciente

$$H_0: \theta \geq \theta_0$$

$$H_1: \theta < \theta_0$$

$$\left. \begin{array}{c} \left. \begin{array}{c} \text{ } \\ \text{ } \end{array} \right. \\ \rightarrow \end{array} \right\} \delta(\underline{x}) = \begin{cases} 1, & -T > k_\alpha \\ 0, & -T \leq k_\alpha \end{cases}$$

**Test con Nivel de Significación Asintótico**

$$\rightarrow \lim_{n \rightarrow \infty} \sup_{\theta \in \mathbb{R}} \pi_{\delta_n}(\theta) = \alpha \quad \therefore P_{\theta=\theta_0}(\delta(\underline{x}) = 1) \xrightarrow{n \rightarrow \infty} \alpha$$

## CAPÍTULO 4

### Intervalos de Confianza de nivel $1-\alpha$

$$\rightarrow P(\theta \in (a(\underline{x}), b(\underline{x})) = 1-\alpha$$

### Método del Pivote

$$U = r(\underline{x}, \theta)$$

$$a \text{ y } b \mid P(a \leq U \leq b) = 1-\alpha$$

$$\left. \begin{array}{l} \\ \end{array} \right\} S(\underline{x}) = \{ \theta : a \leq r(\underline{x}, \theta) \leq b \} \rightarrow \text{región de confianza}$$

### Intervalos de Confianza de nivel Asintótico $1-\alpha$

$$\rightarrow \lim_{n \rightarrow \infty} P(\theta \in S_n(\underline{x})) = 1-\alpha$$

- $\sqrt{n} I(\theta) (\hat{\theta} - \theta) \xrightarrow{a} N(0, 1)$
- $\hat{\theta}$  es consistente para  $\theta$

$$\left. \begin{array}{l} \\ \end{array} \right\} \sqrt{n} I(\hat{\theta}) (\hat{\theta} - \theta) \xrightarrow{a} N(0, 1)$$

### Relación entre Intervalos de Confianza y Test

$$\rightarrow \delta(\underline{x}) = \{ \theta : \delta(\underline{x}) = 0 \} \in \text{región de rechazo de nivel } 1-\alpha$$

## CAPÍTULO 13

### Estimación Bayesiana

$$f_{\Theta|x=x}(\theta) = \frac{f_{\Theta}(x|\theta) f_{\Theta}(\theta)}{\int_{-\infty}^{\infty} f_{\Theta}(x|\theta) f_{\Theta}(\theta) d\theta} \rightarrow \text{a priori}$$

↓  
a posteriori

$$f_x(x)$$

### Estimación de Probabilidades

\* **Discreta**  $P(x_{n+1} > a | x = x) = \sum_{\theta} P(x_{n+1} > a | \Theta = \theta) p_{\Theta|x=x}(\theta)$

\* **Continua**  $P(x_{n+1} > a | x = x) = \int_{a}^{\infty} \int_{-\infty}^{\infty} f_{x_{n+1}|\Theta=\theta}(x) f_{\Theta|x=x}(\theta) d\theta dx$